

“Cryptocurrency (Bitcoin) Price Prediction Using LSTM”

1. Sekilas info *cryptocurrency*

Perkembangan teknologi yang terjadi saat ini membawa pengaruh dalam segala aspek kehidupan, termasuk dalam hal investasi. Banyak bermunculan instrumen-instrumen investasi baru dengan karakteristik dan potensinya yang berbeda-beda. Salah satu instrumen investasi yang populer belakangan ini adalah *cryptocurrency* atau mata uang kripto. *Cryptocurrency* adalah mata uang digital atau virtual yang dijamin dengan kriptografi yang membuatnya tidak mungkin untuk dipalsukan atau digandakan. Kriptografi sendiri merupakan metode yang digunakan untuk melindungi informasi dan saluran komunikasi melalui penggunaan kode.

Selama pandemi COVID-19 yang terjadi dalam kurun dua tahun ini, banyak investor yang khawatir dengan instrumen atau aset yang terdampak menurunnya perekonomian dunia akibat pandemi yang terjadi. Akibatnya, banyak orang yang memindahkan uangnya ke kripto. Hingga saat ini terdapat ribuan mata uang kripto alternatif dengan berbagai fungsi dan spesifikasi. Nilai *cryptocurrency* yang ada saat ini adalah sekitar \$214 miliar. Sebagai *cryptocurrency* berbasis blockchain pertama, Bitcoin saat ini mewakili lebih dari 68% dari total nilai tersebut.

2. Teori Singkat LSTM

Melihat adanya fenomena ini, ingin dibentuk sebuah model yang dapat meramalkan harga Bitcoin dengan baik. Pada penelitian ini, dipilih metode *Long Short Term Memory Network* (LSTM) untuk meramalkan harga Bitcoin beberapa waktu mendatang. *Long Short Term Memory Network* merupakan bentuk pengembangan dari *Recurrent Neural Network* (RNN). RNN adalah sistem algoritma tertua yang telah dikembangkan sejak tahun 1980-an. Sistem ini menjadi satu-satunya sistem yang memiliki memori internal pada masa itu. Sistem ini telah diterapkan oleh Apple dan Google untuk mesin pencarian suara mereka. Kemudian, pada 1990-an, banyak modifikasi yang menyempurnakan RNN, salah satunya adalah LSTM. LSTM terdiri dari serangkaian sel memori unik yang menggantikan neuron lapisan tersembunyi dari RNN. Model LSTM menyaring informasi melalui struktur *gate* untuk mempertahankan dan memperbarui keadaan sel memori. Struktur *gate* mencakup *input gate*, *forget gate*, dan *output gate*. Setiap sel memori memiliki tiga lapisan sigmoid dan satu lapisan tanh.

Algoritma yang digunakan dalam LSTM adalah sebagai berikut (Brownlee, 2017):

1. Menghitung nilai sigmoid dan tanh.
2. Mengubah data yang akan digunakan menjadi supervised learning problem. Supervised learning problem adalah algoritma yang digunakan untuk mempelajari fungsi pemetaan dari input ke output. Karena data yang digunakan adalah data time series maka inputnya adalah data hari kemarin ($t-1$) dan outputnya adalah data hari ini (t).
3. Melakukan normalisasi menggunakan min-max scalling.
4. Menghapus variabel yang tidak dibutuhkan.
5. Membagi data menjadi data training dan testing.
6. Membuat model LSTM yang akan digunakan dengan menentukan banyaknya hidden layer, neuron dan epoch yang akan digunakan. Dalam model LSTM akan dilakukan proses berupa:

- Menghitung nilai forget gate.
 - Menghitung nilai input gate.
 - Memperbarui memori yang berada pada cell.
 - Menghitung output gate dan nilai output akhir.
7. Melakukan evaluasi terhadap model LSTM yang telah dibuat.

3. Kelebihan Kekurangan LSTM

Keuntungan jaringan Long Short-Term Memory (LSTM) dibandingkan RNN yaitu terletak pada metode yang ditingkatkan pada *back propagating the error*. Hochreiter dan Schmidhuber menyebutnya “*constant error back propagation*” atau “perambatan balik kesalahan konstan”. *Back propagation* atau propagasi balik adalah *propagation error* dari prediksi terhadap *weight* atau bobot dan bias. Dalam jaringan berulang seperti RNN dan LSTM istilah ini juga memiliki istilah *Back Propagation Through Time* (BPTT) karena merambat atau *propagates* melalui semua perulangan step meskipun matriks bobot dan bias selalu sama atau konstan. LSTM memungkinkan pengguna untuk melatih model menggunakan ratusan step, sesuatu yang sulit dilakukan oleh RNN. LSTM juga populer karena dapat memecahkan masalah *vanishing gradient*.

4. Mengapa Bitcoin

Salah satu mata uang kripto yang populer akhir-akhir ini adalah Bitcoin. Bitcoin merupakan salah satu cryptocurrency yang menggunakan peer-to-peer untuk proses transaksi. Bitcoin memiliki daya tariknya tersendiri bagi para investor. Saat ini Bitcoin adalah mata uang kripto dengan kapitalisasi atau valuasi pasar terbesar di dunia. Banyak orang yang melakukan perdagangan jual beli Bitcoin sebagai salah satu investasi. Karena pandemi juga, banyak kekhawatiran investor atas instrumen atau aset lain yang bisa terseret kondisi perekonomian dunia akibat pandemi virus Corona (COVID-19) sehingga banyak orang yang melarikan uangnya untuk membeli Bitcoin. Akibatnya, nilai tukar Bitcoin terhadap mata uang yang lain seperti Dolar Amerika semakin meningkat. Bitcoin juga kerap disebut sebagai aset safe-heaven. Aset safe-heaven adalah suatu jenis instrumen yang dinilai lebih aman saat terjadi ketidakpastian ekonomi, politik, maupun geopolitik. Bitcoin juga berpotensi untuk terus tumbuh mengingat jumlah penggunaannya yang semakin meningkat.

Jika dibandingkan dengan cryptocurrency lainnya, bitcoin memiliki volume transaksi yang jauh lebih tinggi. Berdasarkan data pada CoinMarketCap terhitung tanggal 22 Mei 2022 dapat dilihat bahwa perbandingan volume transaksi bitcoin dengan cryptocurrency lainnya berbeda sangat jauh. Contohnya bitcoin dengan empat cryptocurrency lainnya seperti Terra (\$381,422,912), Solana (\$1,787,604,065), Dai (\$699,875,550), dan Ethereum (\$15,234,862,635). Sedangkan bitcoin sendiri sebesar \$28,755,808,670.

Meskipun dapat dikatakan bitcoin merupakan salah satu cryptocurrency yang sedang diminati untuk menjadi media investasi dalam meraih keuntungan secara finansial. Namun, investasi menggunakan bitcoin masih memiliki resiko yang cukup besar. Agar dapat mengantisipasi resiko yang didapat dalam berinvestasi menggunakan Bitcoin, diperlukan suatu sistem prediksi yang dapat memprediksi pergerakan kurs nilai tukar Bitcoin. Untuk memprediksi harga Bitcoin maka data historis harga Bitcoin akan dipelajari hingga mengenali pola-pola tertentu.

5. Ukuran Ketepatan

Untuk menentukan apakah model akurat dalam melakukan peramalan digunakan evaluasi keakuratan prediksi dengan menggunakan dua indeks evaluasi, yaitu Mean Square Error (MSE) dan Mean Absolute Error (MAE). Model terbaik adalah model dengan nilai MSE dan MAE terkecil yaitu mendekati 0. Pada analisis kali ini, diperoleh nilai MSE yaitu sebesar 0.011215928010642529 dan nilai MAE sebesar 0.09207001328468323. Karena diperoleh nilai MSE dan MAE yang mendekati 0, hasil model peramalan yang diperoleh sudah baik.

6. Tahapan analisis

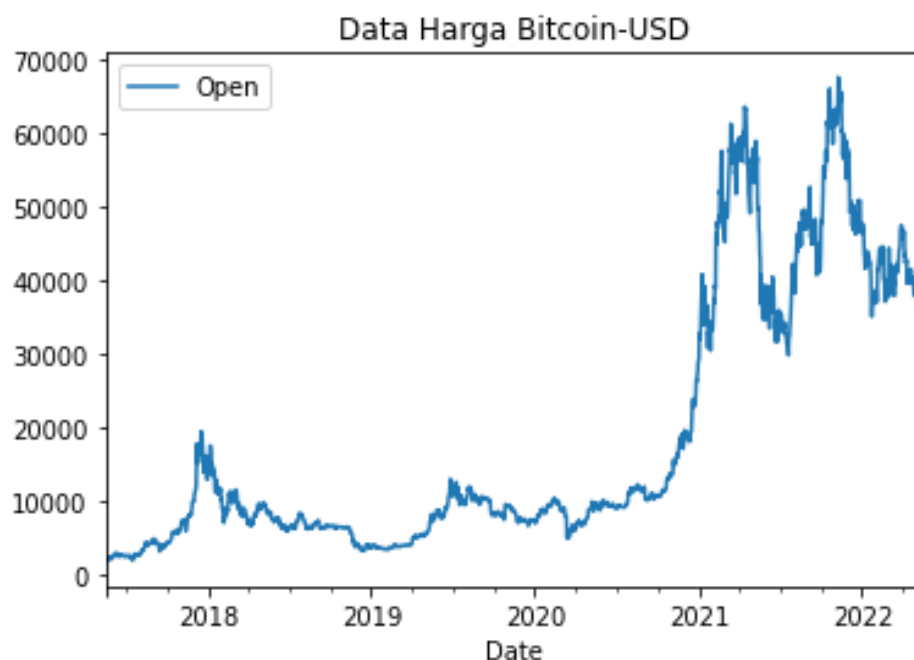
Adapun, tahapan analisis yang kami lakukan adalah sebagai berikut:

- Mengumpul data

Pada kasus kali ini kami menggunakan data dari *yahoo finance* pada laman : <https://finance.yahoo.com/> yang diperoleh dengan menggunakan module dari python yang bernama *yfinance*. Lalu kami pilih *yahoo finance ticker* atau penunjuk untuk symbol aset nya yaitu BTC-USD yang berujuk pada Bitcoin dalam kurs US-Dollar. Kami memilih rentang waktu data yaitu data harian selama dalam 5 tahun terakhir yang dimulai dari 17 Mei 2017 sampai dengan 17 Mei 2022.

- Mempersiapkan data

Setelah diperoleh data nya, kami melakukan pengecekan Panjang data, didapatkan hasil Panjang datanya yaitu 1827. Lalu kami memilih (subsetting data) variabel yang akan digunakan. Pada proses forecasting kali ini kami akan meramalkan harga bitcoin sehingga dipilih variabel *Open*. Selanjutnya kami cek bentuk plot dari data yang akan kami ramalkan selanjutnya sehingga diperoleh plot yang menunjukkan pergerakan harga bitcoin selama 5 tahun terakhir dari 17 Mei 2017 sampai dengan 17 Mei 2022 sebagai berikut :



Gambar 1 : Plot Data Harga Bitcoin Dalam USD

Selanjutnya karena algoritma lstm bekerja dengan input berupa data *sequential* berupa array maka kami ubah data yang kami gunakan (Open) ke dalam format array.

Setelah itu kami melakukan scalling data yang kami gunakan karena biasanya dalam dataset yang masih mentah, beberapa variabel memiliki nilai yang sangat bervariasi dan random, jadi sangat penting untuk di scale feature tersebut,

- Alokasi Data

Setelah data di scaling selanjutnya yang kami lakukan adalah membagi data tersebut menjadi dua bagian yaitu data train dan data test. Dimana data train berguna untuk melatih algoritma untuk mempelajari pola data sehingga menghasilkan output model yang sesuai dan data test berguna untuk mengetahui akurasi dari model yang telah didapatkan melalui data train. Dalam kasus ini kami menggunakan proporsi sebesar 75% untuk data train dan 25% untuk data test. Dipilih proporsi lebih besar untuk data train dikarenakan agar algoritma LSTM lebih memiliki kesempatan yang banyak untuk mempelajari pola dan modelling.

Lalu setelah diperoleh data train dan data test, selanjutnya kami mengubah format data tersebut ke dalam format *sub-sequential*, dikarenakan algoritma LSTM yang digunakan untuk *forecasting* membutuhkan format *sub sequential*. Untuk menjalankan forecasting dengan algoritma *sliding window*. Pada kali ini kami gunakan timestamp=100 yang dimaksudkan yaitu setiap satu data pada variabel X berisi 1 array yang dimana dalam satu array tersebut berisi 100 data runtun waktu. Untuk lebih jelasnya akan kami ilustrasikan dalam tabel berikut

| X | Y |
|---------------------|------|
| [x1,x2,...,x100] | x101 |
| [x2,x3,...,x101] | x102 |
| [x3,x4,...,x102] | x103 |
| ⋮ | ⋮ |
| [xn,xn+1,...,xn+99] | xn+1 |

$$n=1,2,3,4,\dots,N$$

- LSTM Desain


Pada proses ini kami mendesain model LSTM menggunakan tensorflow dan keras dari python. Dengan jumlah neuron sebanyak 50 pada hidden layer 1 dan hidden layer 2. Jumlah neuron tersebut kami pilih berbeda dengan default model LSTM (default neuron = 64) dikarenakan untuk mendapatkan waktu yang efisien untuk melatih model, dengan catatan tetap meminimalkan nilai loss functionnya dimana dalam prose forecasting biasanya digunakan *Mean Squared Error* (MSE) sebagai loss function yang diminimalkan dalam proses.

Lalu kami gunakan fungsi aktivasi untuk untuk membuat neural network menjadi non-linear fungsi aktivasi yang kami gunakan dalam proses mendesain model LSTM kali ini adalah ReLU (Rectified Linear Unit) dimana alasan kami menggunakan nya yaitu fungsi ini aktif Ketika menerima input diatas bilangan 0, karena pada saat proses scaling kami menggunakan MinMaxScaler dalam range 0

sampai 1 maka fungsi aktivasi ReLU baik digunakan. Selain itu juga ReLU sangat mempercepat proses konvergensi yang dilakukan dengan stochastic gradient descent jika dibandingkan dengan sigmoid / tanh. Dimana jika kita bandingkan dengan sigmoid/tanh yang memiliki operasi-operasi yang “expensive” (exponentials, etc.), ReLU bisa kita implementasikan hanya dengan membuat pembatas(threshold) pada bilangan nol.

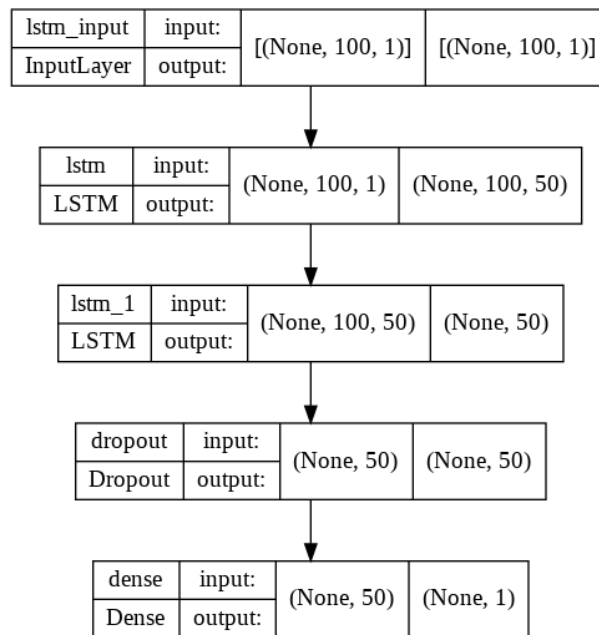
Selanjutnya untuk mengatasi model yang overfitting jika menggunakan jumlah neuron dan/atau hidden layer terlalu banyak, atau data yang digunakan pada pemodelan terlalu kecil. Kami menggunakan Teknik regularisasi dengan menambahkan *layer Dropout* pada LSTM model. Selain itu juga Dropout juga berguna untuk mempercepat waktu latih model, dengan tetap mempertimbangkan nilai *loss function* yang diminimumkan.

Selain itu untuk algoritma optimisasi yang kami gunakan adalah *Adaptive Moment Estimation*(Adam) dikarenakan Adam mengambil keuntungan dari algoritma Gradient Adaptif (AdaGrad) yang mempertahankan learning rate per-parameter yang meningkatkan kinerja pada masalah dengan gradien yang menyebar dan Propagasi Root Mean Square (RMSProp) yang juga mempertahankan learning rate per-parameter yang diadaptasi berdasarkan rata-rata besaran gradien terbaru untuk bobot (mis. Seberapa cepat ia berubah). Artinya, algoritma berfungsi dengan baik pada masalah yang tidak konstan seperti noise. Adam juga populer dikarenakan mencapai hasil yang optimal dengan waktu yang cepat seperti pada gambar berikut.



Sumber : A Method for Stochastic Optimization, 2015.

Dalam algoritma Adam sendiri juga kami definisikan untuk *learning rate*-nya yaitu sebesar 0.001, dikarenakan apabila memakai learning rate yang besar menghasilkan hasil latih yang terlalu cepat sehingga loss function tidak dioptimalkan dengan baik, namun jika lebih kecil akan memperlama waktu dibutuhkan untuk melatih model. Untuk keseluruhan model yang kami gunakan yaitu sebagai berikut :




- Training Data

Pada proses ini kami melatih data yang digunakan untuk menghasilkan model LSTM yang optimal yaitu meminimalkan loss function dengan parameter parameter yang telah disebutkan sebelumnya pada bagian LSTM Desain. Untuk melatih data kami menggunakan Epoch sebesar 100, dan Batch Size sebesar 1. Yang memiliki arti untuk Epoch ketika seluruh dataset sudah melalui proses training pada Neural Network sampai dikembalikan ke awal untuk sekali putaran. Dan batch size adalah berapa banyak data dibagi untuk 1 Epoch nya. Dipilih 100 dikarenakan untuk memperbesar kemungkinan model menemukan nilai MSE yang optimal (kecil) dan batch size 1 agar seluruh data digunakan dalam 1 kali proses latih guna mengoptimalkan model yang didapat.

- Testing data & Evaluasi Model

Setelah proses latih data selesai selanjutnya, kami lakukan testing data untuk mengetahui akurasi dari model yang telah didapatkan melalui data train. Yang menghasilkan *Mean Squared Error* (MSE) sebesar 0.011215928010642529 dan Mean Absolute Error sebesar 0.09207001328468323. berdasarkan MSE dan MAE yang diperoleh menunjukkan hasil peramalan yang diperoleh sudah baik karena mendekati nilai 0. Selain itu juga kami membentuk plot dari hasil prediksi yang telah didapatkan dengan model yang terbentuk.




Gambar 2: Plot Data Harga Asli dan Data Prediksi Bitcoin

Berdasarkan plot data aktual dan data prediksi (train predict data dan test predict data) dapat dilihat baik atau tidaknya hasil dari model yang dibentuk. Plot diatas menggambarkan pola harga prediksi sudah hampir mengikuti pola yang sama dengan harga aktual.

- Forecasting


Selanjutnya setelah didapatkan model LSTM, kamu melakukan proses forecasting sebanyak 30 hari kedepan dengan menggunakan algoritma *sliding window*. *Sliding Window* adalah perkiraan sementara atas nilai aktual dari data deret waktu. *Window Size* dan segmen meningkat sampai kita mencapai perkiraan kesalahan yang lebih sedikit. Setelah memilih segmen pertama, segmen berikutnya dipilih dari akhir segmen pertama. Proses ini diulang sampai semua data time series tersegmentasi. Proses sliding window ditunjukkan pada Gambar 4 dengan window size=5. Jendela geser mengakumulasi data deret waktu historis untuk memprediksi harga penutupan saham hari berikutnya. Gambar 4 menunjukkan proses sliding window dengan window size=5. Setiap angka (1, 2, 3.....10) mewakili pengamatan harian data deret waktu masing-masing hari 1, 2, 3.....10. Awalnya jendela telah ditutup dari 1 hingga 5 yang menunjukkan bahwa data historis 5 hari digunakan untuk prediksi harga penutupan hari berikutnya, kemudian jendela meluncur ke kanan satu hari untuk menutupi 5 hari lagi (dari 2 hingga 6) pengamatan untuk memprediksi hari berikutnya harga tutup. Proses akan dilanjutkan sampai data deret waktu dari periode waktu tertentu.




Gambar 4 : Ilustrasi Algoritma Sliding Window

- Hasil

Setelah dilakukan proses *forecasting* dengan *sliding window* didapatkan hasil peramalan seperti pada plot di bawah ini.



Grafik tersebut menunjukkan 100 data aktual harga bitcoin yang akan diprediksi dengan grafik berwarna biru. Grafik berwarna orange merupakan prediksi yang dihasilkan. Prediksi yang dihasilkan yaitu sebanyak 30 data atau memprediksikan data selama satu bulan sejak data aktual terakhir.



Secara visual terlihat bahwa, dengan metode LSTM univariat, prediksi untuk harga bitcoin yaitu akan terjadi penurunan terus menerus dari prediksi data ke 1 untuk tanggal 18 Mei 2022 sebesar US\$27597,68 hingga prediksi data ke 30 untuk 16 Juni 2022 sebesar US\$14033,18.

7. Kesimpulan

Pergerakan harga bitcoin dari 5 tahun terakhir, yaitu dimulai pada tahun 2017 harga bitcoin berada di harga terendah dibandingkan tahun berikutnya, sekitar US\$ 1726. Lalu, mengalami reli penurunan harga pada tahun 2018 hingga 2019. Terlihat fluktuasi harga yang sangat berbeda antara periode sebelum akhir 2021 dengan periode setelah tahun 2021 terjadinya peningkatan sekitar 134 %.

Selanjutnya, dilihat berdasarkan plot data aktual dan data prediksi (train predict data dan test predict data), dapat dilihat baik atau tidaknya hasil dari model yang dibentuk. Plot diatas menggambarkan, pola harga prediksi sudah hampir mengikuti pola yang sama dengan harga aktual. Perbedaan terbesar terjadi pada periode April hingga bulan September 2021. Selisih terbesar antara harga prediksi dan aktual terjadi pada bulan Mei 2021 dimana harga aktual berada dikisaran 0.7 USD sedangkan harga prediksi berada pada kisaran 0.4 USD.

Nilai keakuratan hasil peramalan yang digunakan adalah MAE dan nilai MAE diperoleh sebesar 0.09207001328468323 sehingga nilai MAPE adalah 9,207%.

Dari nilai MAPE tersebut dapat dilihat bahwa hasil prediksi dengan menggunakan 50 neuron pada hidden layer dan 100 epoch memiliki nilai akurasi sebesar 90,793 %.

Memprediksi harga Bitcoin bukanlah tugas yang mudah, dilihat pada grafik Gambar 2 naik-turun tidak beraturan, dan juga naik drastis sehingga Bitcoin belum pernah stabil dalam jangka waktu yang lama.

Hasil *forecasting* yang diperoleh berdasarkan model yang didapatkan dari proses training menunjukkan harga bitcoin mengalami penurunan. Hal ini terlihat dari garis kuning yang merupakan hasil forecast turun.